Proyecto 1: Desempleo y empleo informal en Honduras

Estructura de trabajo: pipeline con SQL y Python, tablero documentado y piezas reutilizables para la tesis y el portafolio

Preparado para Manu | Tegucigalpa, Honduras

Qué es este proyecto. Un análisis reproducible de la Encuesta Permanente de Hogares de Propósitos Múltiples (EPHPM) que termina en un tablero interactivo, documentado en GitHub, y en un conjunto de tablas limpias que alimentan tu tesis.
Por qué aplica la certificación. Cada fase practica una parte de lo que enseña el curso de Google (preparación de datos, consultas SQL, visualización y presentación de resultados). La sección 3 mapea el vínculo módulo por módulo.
Fecha objetivo. Publicación en GitHub y LinkedIn hacia el 6 de diciembre de 2026, según la hoja de ruta de 90 días.

1. Objetivos y entregables

Entregable	Descripción	Uso
Repositorio en GitHub	Código, consultas SQL, documentación y datos procesados de muestra	Portafolio y evaluación técnica
Tablero publicado (Power BI Desktop)	Indicadores de desempleo, informalidad e ingreso por sexo, edad, área y departamento	Demostración a empleadores
Notebook de análisis	Hallazgos con gráficos y lectura de resultados, sin jerga técnica innecesaria	Entrevistas y tesis
Tablas limpias y diccionario de datos	Base armonizada 2001 a 2024 o el periodo disponible	Insumo directo de la tesis
Post en LinkedIn y resumen de 1 página	Pregunta, hallazgo principal, enlace al tablero	Visibilidad y primer contacto

2. Preguntas que guían el análisis

- **P1.** ¿Cómo ha evolucionado la tasa de desempleo abierto en Honduras entre 2001 y el último año disponible, y qué diferencias hay por sexo, edad y área (urbana o rural)?
- **P2.** ¿Qué proporción de la población ocupada se encuentra en empleo informal, y cómo se distribuye por departamento y nivel educativo?
- **P3.** ¿Qué brecha de ingreso laboral existe entre ocupados formales e informales, controlando por años de escolaridad y sexo? (esta pregunta enlaza directamente con tu modelo de la tesis)

Cada pregunta define un bloque del tablero y una consulta SQL principal. Si una pregunta no aporta a una decisión o a la tesis, se elimina antes de construir la página.

3. Qué aplicas de la certificación, y dónde

Nota de verificación. Antes de cerrar esta tabla, confirma en el temario de tu curso qué herramientas exactas se enseñan en cada módulo. Las correspondencias de abajo son las habituales en certificaciones de analítica en Google Cloud; ajústalas a lo que realmente cubre tu programa.

Competencia de la certificación	Aplicación en el proyecto	Fase
Preparación y limpieza de datos (detectar nulos, duplicados, tipos y valores atípicos)	Limpieza de la EPHPM: variables de factor de expansión, códigos de categorías, nulos por módulo	Fase 1
Consultas SQL (joins, agregaciones, subconsultas y funciones de ventana)	Construcción de tablas de hechos y dimensiones y cálculo de indicadores por grupo	Fases 2 y 3
BigQuery y Google Cloud básico	Versión opcional: carga de las tablas a BigQuery para practicar la nube. El flujo principal corre en DuckDB	Fase 2 (opcional)
Visualización y presentación de datos	Tablero en Power BI Desktop con filtros, KPI y comparaciones	Fase 4
Documentación y comunicación de hallazgos	README, diccionario de datos, notebook y resumen ejecutivo	Fase 5
Ética y uso responsable de datos	Uso de datos públicos, anonimato y limitaciones explicitadas en el tablero	Transversal

4. Fuentes de datos y restricciones

- **Fuente principal:** microdatos de la EPHPM publicados por el Instituto Nacional de Estadística (INE) de Honduras. Antes de descargar, verifica en el sitio del INE si la publicación es de acceso libre y qué condiciones de uso aplican; deja la referencia exacta en el README.
- **Diccionarios y cuestionarios:** documentación metodológica de cada año. Las variables cambian entre rondas (nombres, categorías y, en algunos años, la clasificación de ocupación); cada cambio se anota en un archivo de armonización.
- **Factores de expansión:** todos los indicadores deben ponderarse por el factor de expansión. Un conteo sin ponderar no representa a la población.
- **Datos de referencia (opcional):** series del Banco Central de Honduras o de la CEPAL para contrastar tendencias del desempleo.
- **Restricción:** no se publica el archivo crudo en GitHub si la licencia no lo permite; el repositorio incluye el código para reconstruirlo y una muestra sintética.

5. Arquitectura del pipeline y stack de herramientas

Capa	Contenido	Herramienta	Salida
Raw	Archivos originales tal como se descargan, con fecha y hash	Carpeta local (opcional: Cloud Storage)	Archivos inmutables
Limpieza	Tipos de datos, códigos armonizados, nulos tratados, variables derivadas	Python (pandas)	Parquet o CSV por año
Staging	Una tabla por año, con el mismo esquema	dbt Core + SQL en DuckDB	stg_ehpm_personas, stg_ehpm_hogares
Marts	Tabla de personas con indicadores ya calculados y ponderados	dbt Core + SQL en DuckDB	mart_mercado_laboral

Capa	Contenido	Herramienta	Salida
Tablero	Visualizaciones y filtros sobre el mart	Power BI Desktop (alterna: Looker Studio)	Archivo .pbix y enlace público

Stack de herramientas elegido

Función	Herramienta elegida	Licencia	Criterio de demanda
Consultas SQL	DuckDB (motor principal) con SQL estándar	Abierta	SQL aparece en alrededor de 53 a 70 % de las ofertas de analista
Limpieza y análisis	Python con pandas y Jupyter	Abierta	Python aparece en 31 a 55 % de las ofertas
Transformación y modelos	dbt Core	Abierta	Relevante para la transición a analytics engineering
Hojas de cálculo	Excel (web, gratuito con cuenta Microsoft); LibreOffice para trabajo libre	Propietaria / abierta	Excel aparece en 60 a 81 % de las ofertas en algunos conjuntos
Tablero	Power BI Desktop; alterna Looker Studio o Metabase	Gratuita, propietaria	Power BI aparece en alrededor de 43 % de las ofertas; Tableau pesa más en puestos senior
Control de versiones	Git y GitHub	Abierta	Esperado en roles técnicos en general
Documentación	Markdown y Quarto	Abierta	Sirve al README, al notebook y a la tesis
Nube (opcional)	BigQuery con capa gratuita	Propietaria	Menos presente en ofertas de analista; útil como puente a la certificación

- **Criterio:** lo que determina el flujo de datos es libre y reproducible; lo que determina la contratación (SQL, Python, Excel y Power BI) se practica en las herramientas que más se piden.
- **Supuesto:** Power BI Desktop solo corre en Windows. Si el equipo no es Windows, el tablero se hace en Looker Studio con las mismas tablas, sin cambiar el modelo de datos.
- **Fuentes de demanda:** análisis de anuncios de empleo publicados en 2025 y 2026 por terceros, con métodos distintos. Las cifras son orientativas y conviene revisarlas con ofertas de Honduras y México antes de cerrar decisiones de largo plazo.

6. Modelo de datos y variables clave

Tabla	Grano	Variables principales
stg_personas	Una fila por persona y año	año, id de hogar, sexo, edad, área, departamento, escolaridad, condición de actividad, categoría de ocupación, ingreso, factor de expansión
stg_hogares	Una fila por hogar y año	año, id de hogar, departamento, área, número de miembros, factor de expansión del hogar
dim_fecha	Una fila por año	año, periodo de referencia, indicador de cambio metodológico
dim_territorio	Una fila por departamento	código, nombre, región
mart_mercado_laboral	Una fila por año, sexo, grupo de edad, área y departamento	población en edad de trabajar, PEA, ocupados, desocupados, ocupados informales, tasas e ingreso medio ponderados

7. Definición de indicadores

Cada indicador se define en el diccionario del repositorio con su fórmula, su fuente de variables y su limitación. Las definiciones siguen el marco de la OIT (Conferencia Internacional de Estadísticos del Trabajo).

Indicador	Fórmula (ponderada)	Nota
Tasa de desempleo abierto	Desocupados / PEA x 100	Compara con la definición oficial del INE; las diferencias de criterio se documentan.
Tasa de participación	PEA / población en edad de trabajar x 100	Se calcula para la población en edad de trabajar definida en el INE.
Tasa de informalidad	Ocupados informales / ocupados x 100	Definición operativa según la variable de afiliación o de tipo de empleo disponible en cada año.
Ingreso laboral medio	Suma ponderada del ingreso / suma ponderada de ocupados	Precios corrientes; se advierte si no se deflacta. Si se deflacta, la fuente del índice se cita.
Brecha de ingreso	Ingreso medio de un grupo / ingreso medio de referencia	Se reporta siempre con su intervalo o advertencia de muestra.

8. Controles de calidad automatizados

- **Esquema:** mismas columnas y tipos en todos los años; falla si cambian sin registro en el archivo de armonización.
- **Unicidad:** una persona por combinación de hogar y número de orden dentro de cada año.
- **Rangos:** edad entre 0 y 110; escolaridad y categorías dentro de los códigos del diccionario.
- **Totales de control:** la suma de factores de expansión por año debe acercarse a la población publicada por el INE (tolerancia documentada).
- **Consistencia lógica:** ocupados y desocupados no pueden ser ambos verdaderos; ingreso cero o nulo debe justificarse por condición de actividad.
- **Reporte:** cada ejecución genera un archivo con los resultados de los controles, que se incluye en el repositorio.

9. Diseño del tablero

Página	Contenido	Preguntas que responde
1. Resumen	Cuatro KPI (tasa de desempleo, participación, informalidad, ingreso medio) con variación frente al año anterior y nota metodológica	Panorama general (P1 y P2)
2. Tendencias	Series de tiempo 2001 a 2024 por sexo y área; selector de indicador	P1
3. Grupos	Desempleo e informalidad por edad, sexo y escolaridad	P1 y P2
4. Territorio	Mapa o barras por departamento con filtro por año	P2
5. Brecha de ingreso	Ingreso medio formal frente a informal, con filtros de escolaridad y sexo	P3 (enlaza con la tesis)
6. Metodología	Definiciones, fuentes, limitaciones y enlace al repositorio	Credibilidad y transparencia

- **Reglas de diseño:** máximo cuatro KPI por página; títulos que digan la conclusión (por ejemplo, "El desempleo femenino duplica al masculino en 2024"); misma paleta en todas las páginas; etiquetas en español con cifras en formato hondureño.
- **Filtros globales:** año, sexo, área y departamento. Cada filtro se prueba para que ningún gráfico quede vacío.
- **Lectura para no técnicos:** una nota breve bajo cada gráfico con la pregunta que responde y cómo leerlo.

10. Plan de trabajo por fases

Fase	Semanas	Trabajo	Horas aprox.
1. Datos y limpieza	Semanas 2 a 4 (8 nov a 22 nov)	Descargar la EPHPM, armonizar años, escribir los controles de calidad y el diccionario de datos	14
2. Modelado en SQL	Semanas 4 a 5 (16 a 29 nov)	Cargar en DuckDB, staging y mart con dbt Core, consultas de validación contra cifras publicadas	12
3. Análisis	Semanas 5 a 6 (23 nov a 6 dic)	Responder P1, P2 y P3 en el notebook; anotar limitaciones y decisiones	10
4. Tablero	Semana 6 (30 nov a 6 dic)	Construir las 6 páginas en Power BI Desktop, probar filtros, revisar lectura para no técnicos	8
5. Publicación	Semana 7 (7 a 13 dic)	README final, diccionario, post en LinkedIn, resumen de una página, enlace al tablero	6

Total: unas 50 horas, repartidas en el frente B de la hoja de ruta. Si el tiempo se acorta, se recorta la página 4 del tablero, nunca los controles de calidad ni la documentación.

11. Estructura del repositorio

```
proyecto1-ehpm-desempleo/
■■■ README.md          (problema, fuentes, cómo reproducir, hallazgos, limitaciones)
■■■ data/
■   ■■■ raw/            (no versionado si la licencia lo impide)
■   ■■■ processed/    (tablas limpias)
■   ■■■ sample/      (muestra sintética para probar el pipeline)
■■■ src/           (ingesta, limpieza, controles de calidad)
■■■ sql/           (consultas de validación y de exploración)
■■■ dbt/           (modelos staging y mart con dbt Core)
■■■ notebooks/     (análisis de P1, P2 y P3)
■■■ dashboard/     (archivo .pbix, capturas, enlace y guía de uso)
■■■ docs/
■   ■■■ data_dictionary.md
■   ■■■ indicadores.md
■   ■■■ armonizacion.md   (cambios entre rondas)
■■■ tests/         (pruebas de esquema y de rangos)
```

Reglas de versionado: commits pequeños con mensaje claro (por ejemplo, "Armoniza códigos de área en EPHPM 2010"); una rama por fase; ninguna credencial ni ruta personal en el código.

12. Uso doble: tesis y portafolio

La clave es separar qué va a cada destino para no mezclar un trabajo de tesis con un producto de empleo.

Pieza	Portafolio y empleadores	Tesis
Pipeline de limpieza y controles	Sí, como evidencia técnica	Sí, como anexo metodológico
Tablas limpias 2001 a 2024	Solo muestra sintética	Sí, es la base de datos del modelo
Tablero	Sí, es el producto principal	Figuras descriptivas seleccionadas

Pieza	Portafolio y empleadores	Tesis
Modelos Logit y Probit	No en esta fase (se presenta el resultado en una frase)	Sí, centro del capítulo empírico
Notebook de hallazgos	Versión corta para lectura	Capítulo de resultados descriptivos

Advertencia académica. Si el tablero o el notebook publican resultados antes de que la tesis los defienda, consulta con tu director (Gabriel Montes Rojas, según tu registro) si eso afecta la originalidad o el calendario. Una regla práctica es publicar las estadísticas descriptivas y dejar los resultados del modelo para después de la defensa.

13. Cómo presentar el proyecto a empleadores

- **Resumen de una página (en inglés y español):** problema, datos, método, tres hallazgos y enlace.
- **Demostración de 3 minutos:** abrir el tablero, mostrar un filtro que cambie una conclusión, abrir una consulta SQL del mart y explicar un control de calidad que detectó un problema real.
- **Preguntas típicas y respuestas preparadas:** ¿por qué ponderaste?, ¿cómo manejaste los cambios de cuestionario?, ¿qué harías distinto con más tiempo?
- **Post en LinkedIn:** una pregunta, un gráfico, un hallazgo y el enlace. Sin tecnicismos en el primer párrafo.

14. Riesgos y respuesta

Riesgo	Señal temprana	Respuesta
Cambios de variables entre años	Errores de esquema en la semana 2	Archivo de armonización y pruebas de esquema; reducir el periodo si la armonización no es viable.
Cifras que no cuadran con el INE	Totales ponderados muy distintos	Revisar factores de expansión y filtros de edad y población; documentar la diferencia si persiste.
Licencia de datos no clara	Sin respuesta del INE tras la primera semana	Usar la muestra sintética y describir el procedimiento; la tesis tiene su propia ruta de acceso.
Tiempo insuficiente por certificación o búsqueda	Fase 1 se extiende más de 2 semanas	Recortar la página 4 del tablero; mantener controles y documentación.
Sin Windows para Power BI Desktop	No instala o no abre el archivo .pbix	Usar Looker Studio con las mismas tablas; el modelo no cambia.

15. Lista de cierre

- Controles de calidad pasan en todos los años y el reporte está en el repositorio.
- Indicadores ponderados y comparados con cifras publicadas por el INE (con diferencias explicadas).
- Tablero con 6 páginas, filtros probados y enlace público activo.
- README con problema, fuentes, reproducción en pocos comandos, hallazgos y limitaciones.
- Diccionario de datos e indicadores completos; armonización documentada.
- Resumen de una página y post de LinkedIn publicados.
- Acuerdo con el director de tesis sobre lo que se publica y cuándo.