Proyecto de Portafolio: World Bank WDI

El proyecto diferenciador — una guía paso a paso donde cada concepto de la certificación que se pone en práctica queda explícito, para que el conocimiento deje de vivir al nivel de las definiciones y empiece a vivir en decisiones que tú mismo tomaste.

Esta guía está construida alrededor de un solo objetivo: cerrar la brecha entre reconocer un término en una diapositiva y recurrir a él por criterio propio. Cada paso de abajo lleva una etiqueta morada **CONCEPTO(S) DE LA CERTIFICACIÓN** que nombra exactamente qué parte de la certificación pone en práctica ese paso, y una etiqueta verde **DÓNDE EJECUTARLO** que te dice en qué pantalla exacta de la consola va cada comando o consulta — así, al final, tienes tanto un proyecto funcional como un mapa literal de dónde vive realmente cada pieza del contenido del curso dentro de trabajo real.

> **Antes de empezar: confirma el esquema.**
> Los nombres de tablas y columnas de abajo reflejan la estructura estándar de bigquery-public-data.world_bank_wdi, pero los datasets públicos ocasionalmente se reestructuran. Ejecuta `bq show --schema bigquery-public-data:world_bank_wdi.indicators_data` (y lo mismo para las demás tablas mencionadas abajo) antes de confiar en los nombres exactos de columnas — trata lo que sigue como una plantilla sólida de partida, no como una garantía verificada.

Paso 0 — Cómo moverte en la consola: dónde escribes cada cosa

Antes de tocar un solo concepto de la certificación, vale la pena dejar clarísimo algo puramente mecánico: en Google Cloud hay **dos lugares distintos** donde se escriben comandos, y confundirlos es la causa más común de "no me funciona nada". Esta sección es tu mapa de navegación fijo para el resto de la guía.

A. La terminal de Cloud Shell (para comandos que empiezan con bq o gcloud)

1. En la Google Cloud Console (console.cloud.google.com), busca el ícono de terminal >_ en la esquina superior derecha de la barra superior, junto a la campana de notificaciones y tu foto de perfil. Haz clic ahí.
2. Se abrirá un panel en la parte inferior de la pantalla. Si ese panel muestra un **Editor** de archivos (un árbol de carpetas a la izquierda, un archivo de texto abierto en el centro — parecido a VS Code) en lugar de una ventana negra de terminal, busca el botón **"Abrir terminal"** en la esquina superior derecha de ese panel y haz clic ahí. El Editor es para escribir archivos de código; la Terminal es para ejecutar comandos, y son cosas distintas dentro del mismo panel de Cloud Shell.
3. Una vez que veas una línea de comandos con un cursor parpadeante (algo como `tu_usuario@cloudshell:~$`), ese es el lugar correcto. Pega o escribe el comando ahí y presiona Enter.

> **Regla simple para todo lo que sigue:**
> Si el comando empieza con `bq` o `gcloud`, va en la **Terminal de Cloud Shell**. Si el comando empieza con `SELECT`, `CREATE TABLE`, `CREATE OR REPLACE TABLE` o cualquier otra instrucción de SQL, va en el **editor SQL de BigQuery Studio** (sección B, abajo) — nunca en la Terminal.

B. El editor SQL de BigQuery Studio (para SELECT, CREATE TABLE, etc.)

1. En la Google Cloud Console, haz clic en el ícono de menú (las tres líneas horizontales ≡) en la esquina superior izquierda, o simplemente escribe **"BigQuery"** en la barra de búsqueda superior y selecciona **"BigQuery Studio"** de los resultados. También puedes usar el acceso directo **BigQuery** que aparece en la sección "Acceso rápido" del panel principal de tu proyecto.

2. Dentro de BigQuery Studio verás tres zonas: a la izquierda el **Explorador** (lista de proyectos y datasets, incluyendo cualquiera al que te hayas suscrito), en el centro-arriba un botón azul **“+”** o **“Consulta nueva” / “Compose new query”** que abre una pestaña en blanco, y debajo de esa pestaña el área de resultados, donde aparecen las filas después de ejecutar.
3. Haz clic en **“Consulta nueva”** para abrir una pestaña de edición vacía. Ahí es donde pegas cualquier bloque de SQL de esta guía.
4. Para ejecutar, usa el botón azul **“Ejecutar” / “Run”** arriba de la pestaña (o el atajo Ctrl+Enter / Cmd+Enter). Los resultados aparecen en el panel inferior en segundos.

C. Sobre “suscribirte” a un dataset público vía Analytics Hub

Si ya usaste un botón de “Suscribirse” sobre el dataset de WDI, no hiciste nada incorrecto — es un camino alternativo y válido para acceder a un dataset público, mediante Analytics Hub. Lo que ocurre es que se crea una **referencia enlazada** (no una copia) dentro de tu propio proyecto, visible en el Explorador de BigQuery Studio bajo tu proyecto `world-bank-wdi`, normalmente con un nombre parecido al de la suscripción. A partir de ahí, cualquier consulta de esta guía funciona igual, solo que en vez de escribir `bigquery-public-data.world_bank_wdi.indicators_data` usarías el nombre que aparece en tu propio Explorador, por ejemplo `world-bank-wdi.NOMBRE_DEL_DATASET.indicators_data`. Revisa el Explorador para confirmar el nombre exacto antes de continuar.

Paso 1 — Entender por qué este proyecto es estructuralmente distinto al de Olist

> **CONCEPTO(S) DE LA CERTIFICACIÓN:** **Analytics Hub y datasets vinculados (linked datasets) · sistemas de registro vs. cloud storage vs. base de datos transaccional**

Con Olist hiciste todo el recorrido de datos crudos a datos curados tú mismo, porque los datos partían de archivos planos que tenías que ingerir. WDI es distinto: ya es un dataset de BigQuery gobernado y publicado, al que accedes mediante una suscripción (técnicamente, Google lo publica y tú lo consultas como una referencia vinculada) — exactamente el patrón de "referencia en vivo sin copiar" detrás de Analytics Hub. Eso significa que los Pasos 1–2 de la guía de Olist (descargar archivos crudos, crear una zona de aterrizaje en Cloud Storage, bq load) simplemente no existen aquí. Este proyecto empieza un nivel más arriba: en datos que no ingeriste tú, solo validaste y reestructuraste.

Paso 2 — Descubre y valida la fuente, antes de escribir una sola consulta

> **CONCEPTO(S) DE LA CERTIFICACIÓN:** **Data Catalog / metadatos (técnicos y de negocio) · el flujo de trabajo exclusivo del analista (descubrir → validar)**

Trata el dataset público exactamente como una entrada de catálogo que estás validando por primera vez, no como un dato dado.

> ■ **DÓNDE EJECUTARLO:** **Editor SQL de BigQuery Studio (sección B del Paso 0) — no la Terminal. En el Explorador de la izquierda, busca tu proyecto → si te suscribiste vía Analytics Hub, el dataset ya aparece listado ahí directamente; si no, escribe “bigquery-public-data” en el buscador del propio Explorador, presiona Enter, y navega hasta el proyecto “bigquery-public-data” → dataset “world_bank_wdi”. Haz clic sobre el dataset para ver su descripción, y expándelo para ver la lista de tablas que contiene.**

Las tablas estándar que deberías encontrar son:

Tabla	Grano (1 fila =)	Uso típico
indicators_data	un país + indicador + año	La tabla principal con forma de hechos — formato largo/angosto.
country_summary	un país	Metadatos del país: región, grupo de ingreso, moneda.
series_summary	un indicador	Definiciones de indicadores, unidades, fuente, periodicidad — tu fuente para el glosario de negocio.
country_series_definitions	un país + indicador	Notas específicas por país sobre cómo se define una serie.
series_time	un indicador + rango de años	Notas al pie sobre cambios en la definición a lo largo del tiempo.
footnotes	un país + indicador + año	Notas puntuales (p. ej., estimado vs. reportado).

Nota que este es el mismo paso de descubrimiento del flujo de trabajo exclusivo del analista que vimos antes — estás verificando qué es una tabla y si confiar en ella antes de construir algo encima, exactamente como revisar los metadatos de una entrada de catálogo antes de una consulta real de análisis.

Paso 3 — Perfila y valida antes de confiar en los números

> **CONCEPTO(S) DE LA CERTIFICACIÓN:** **Gobernanza de datos: componente de gestión de calidad · dimensiones de calidad de datos (completitud, consistencia)**

> ■ **DÓNDE EJECUTARLO:** **Editor SQL de BigQuery Studio. Pega el bloque de abajo completo en una pestaña de “Consulta nueva” y haz clic en “Ejecutar”.**

```
-- Chequeo de cobertura: ¿cuántos países/años tiene realmente un indicador dado?
SELECT
  indicator_code,
  COUNT(DISTINCT country_code) AS countries_covered,
  MIN(year) AS first_year,
  MAX(year) AS last_year,
  COUNTIF(value IS NULL) AS null_values
FROM `bigquery-public-data.world_bank_wdi.indicators_data`
WHERE indicator_code IN ('SL.UEM.TOTL.ZS', 'NY.GDP.MKTP.KD.ZG', 'SL.TLF.CACT.ZS')
GROUP BY indicator_code;
```

Una advertencia propia de un economista, que vale la pena documentar y no solo notar:
La cobertura de WDI es desigual entre países y años por construcción — los países más pequeños o de menores ingresos suelen tener vacíos que las economías grandes no tienen, y algunos valores son estimaciones modeladas en vez de reportes directos. Dejar esta limitación por escrito de forma explícita (en tu diccionario de datos del Paso 7) es en sí mismo una práctica de gobernanza y gestión de calidad, no solo un detalle de rigor propio de la economía.

Paso 4 — Reconoce el formato crudo: esto es normalización en su forma más extrema

CONCEPTO(S) DE LA CERTIFICACIÓN: Normalización vs. desnormalización

`indicators_data` guarda cada observación como una sola fila: (país, indicador, año, valor). Es un formato entidad-atributo-valor — prácticamente todo lo normalizada que una tabla puede llegar a estar, ya que nunca repite una columna por indicador. Es eficiente y flexible para almacenamiento, pero casi inutilizable directamente para análisis: comparar el desempleo contra el crecimiento del PIB para el mismo país-año significa que los dos números viven en filas completamente distintas. Este es exactamente el problema que la desnormalización existe para resolver, y es una ilustración más limpia del concepto que la que dio Olist, porque aquí el estado "antes" está maximamente normalizado en vez de solo normalizado de forma común.

Paso 5 — Pivotea: desnormaliza datos largos en un esquema en estrella listo para análisis

> **CONCEPTO(S) DE LA CERTIFICACIÓN:** **Técnica de desnormalización: pivoteo · esquema en estrella (hechos + dimensiones)**

Elige un conjunto de indicadores relevantes para tu propio campo — desempleo, crecimiento del PIB, participación en la fuerza laboral, inflación y PIB per cápita son un conjunto natural dado tu trasfondo. Pivotéalos desde filas largas hacia una sola tabla de hechos ancha, a nivel de país-año.

> ■ **DÓNDE EJECUTARLO: Editor SQL de BigQuery Studio. Primero necesitas un dataset propio donde guardar las tablas nuevas: en el Explorador, haz clic en los tres puntos junto al nombre de tu proyecto (`world-bank-wdi`) → "Crear conjunto de datos" / "Create dataset", y nómbralo `wdi_curated`. Luego pega el bloque de abajo en una pestaña de "Consulta nueva" y ejecútalo — creará las tablas dentro de ese dataset.**

```
CREATE OR REPLACE TABLE `TU_PROJECT_ID.wdi_curated.fct_country_year` AS
SELECT
  country_code,
  year,
  MAX(IF(indicator_code = 'SL.UEM.TOTL.ZS', value, NULL)) AS unemployment_pct,
  MAX(IF(indicator_code = 'NY.GDP.MKTP.KD.ZG', value, NULL)) AS gdp_growth_pct,
  MAX(IF(indicator_code = 'SL.TLF.CACT.ZS', value, NULL)) AS labor_force_participation_pct,
  MAX(IF(indicator_code = 'FP.CPI.TOTL.ZG', value, NULL)) AS inflation_pct,
  MAX(IF(indicator_code = 'NY.GDP.PCAP.CD', value, NULL)) AS gdp_per_capita_usd
FROM `bigquery-public-data.world_bank_wdi.indicators_data`
WHERE indicator_code IN (
  'SL.UEM.TOTL.ZS','NY.GDP.MKTP.KD.ZG','SL.TLF.CACT.ZS','FP.CPI.TOTL.ZG','NY.GDP.PCAP.CD'
)
GROUP BY country_code, year;

CREATE OR REPLACE TABLE `TU_PROJECT_ID.wdi_curated.dim_country` AS
SELECT country_code, short_name, region, income_group, currency_unit
FROM `bigquery-public-data.world_bank_wdi.country_summary`;
```

`fct_country_year` es tu tabla de hechos (una fila por país-año); `dim_country` es tu dimensión. Es el mismo patrón de esquema en estrella de Olist, pero la técnica de desnormalización es el pivoteo en vez del JOIN — vale la pena señalarlo de forma explícita, ya que la certificación presenta estas como técnicas separadas y este proyecto es donde realmente usas la que Olist no requería.

Recuerda reemplazar `TU_PROJECT_ID` por el ID real de tu proyecto (lo encuentras en el panel principal de la consola, donde dice "ID del proyecto" — en tu caso, algo como `world-bank-wdi`) antes de ejecutar cualquier consulta de esta guía.

Paso 6 — Agrupa indicadores relacionados con STRUCT

> **CONCEPTO(S) DE LA CERTIFICACIÓN:** **STRUCT / datos anidados**

Desempleo y participación en la fuerza laboral son conceptualmente un mismo tema ("mercado laboral"); crecimiento del PIB y PIB per cápita son otro ("producto"). Anidarlos hace explícito ese agrupamiento directamente en el esquema, en vez de dejarlo implícito en cinco columnas planas:

> ■ **DÓNDE EJECUTARLO: Editor SQL de BigQuery Studio, misma pestaña o una nueva — igual que el Paso 5.**

```
CREATE OR REPLACE TABLE `TU_PROJECT_ID.wdi_curated.fct_country_year_nested` AS
SELECT
  country_code,
  year,
  STRUCT(
    unemployment_pct,
    labor_force_participation_pct
  ) AS labor_market,
  STRUCT(
    gdp_growth_pct,
    gdp_per_capita_usd
  ) AS output,
  inflation_pct
FROM `TU_PROJECT_ID.wdi_curated.fct_country_year`;
```

Consúltalo de vuelta con `labor_market.unemployment_pct` — un buen lugar, de bajo riesgo, para sentir el costo de verbosidad en las consultas que introduce STRUCT, sobre datos que ya entiendes.

Paso 7 — Un enfoque de gobernanza adecuado para datos estadísticos públicos

> **CONCEPTO(S) DE LA CERTIFICACIÓN: Gobernanza de datos: componentes de políticas y estándares, gestión de calidad**

WDI es público y no sensible, así que el ángulo de gobernanza de privacidad/seguridad de Olist no aplica realmente aquí — pero otros dos componentes de gobernanza sí, y importan más para datos estadísticos públicos de lo que la gente suele asumir:

- **Atribución y licenciamiento (políticas y estándares):** los datos del Banco Mundial tienen requisitos de citación. Documenta la fuente y la atribución requerida en tu README exactamente como documentarías una política de retención — es la misma categoría de gobernanza, solo una regla distinta.
- **Documentación de limitaciones conocidas (gestión de calidad):** registra, en tu diccionario de datos, qué indicadores tuvieron tasas altas de nulos para qué regiones/períodos, y dónde un valor es una estimación modelada en vez de una medición directa. Esta es una práctica de gestión de calidad genuinamente más rigurosa de lo que la mayoría de proyectos de portafolio se molesta en hacer — y juega directamente a favor del instinto de un economista de interrogar una fuente de datos en vez de tratarla como verdad absoluta.

Este paso es de documentación (README, diccionario de datos) — no requiere ejecutar nada nuevo en la consola; usa un editor de texto normal o el mismo repositorio de GitHub donde subirás el proyecto.

Paso 8 — Escribe el diccionario de datos / entrada de catálogo para lo que construiste

CONCEPTO(S) DE LA CERTIFICACIÓN: Data Catalog / metadatos · glosario de negocio

El mismo ejercicio que en Olist, aplicado a tus nuevas tablas curadas — más un agregado: usa las propias definiciones de indicadores de `series_summary` como tu fuente para el glosario de negocio, en vez de escribir definiciones desde cero.

Tabla	Grano	Columnas clave	Notas
fct_country_year	un país-año	country_code, year	Tabla de hechos ancha, pivoteada — ver Paso 5.
dim_country	un país	country_code (PK)	Región y grupo de ingreso desde country_summary.
unemployment_pct	—	—	SL.UEM.TOTL.ZS — % de la fuerza laboral sin trabajo, buscando empleo (según series_summary).

Paso 9 — Responde preguntas reales (aquí es donde el proyecto se gana lo de "diferenciador")

CONCEPTO(S) DE LA CERTIFICACIÓN: Flujo de trabajo del analista: consultar, interpretar, reportar

■ DÓNDE EJECUTARLO: Editor SQL de BigQuery Studio, para ambas consultas de esta sección.

9a. Tendencias de desempleo en América Latina

```
SELECT c.short_name, f.year, f.unemployment_pct
FROM `TU_PROJECT_ID.wdi_curated.fct_country_year` f
JOIN `TU_PROJECT_ID.wdi_curated.dim_country` c ON f.country_code = c.country_code
WHERE c.region LIKE '%Latin America%'
ORDER BY c.short_name, f.year;
```

9b. Crecimiento del PIB vs. desempleo — una verificación al estilo de la ley de Okun entre países

```
SELECT country_code, year, gdp_growth_pct, unemployment_pct
FROM `TU_PROJECT_ID.wdi_curated.fct_country_year`
WHERE gdp_growth_pct IS NOT NULL AND unemployment_pct IS NOT NULL
ORDER BY country_code, year;
```

Un puente natural (opcional) hacia tu tesis:
Esta relación entre crecimiento del PIB y desempleo entre países es la misma pregunta empírica que tu tesis examina específicamente para Honduras. Nada de esto debería reformular la tesis en sí, pero tener ya construido un punto de comparación entre países es algo genuinamente útil de tener a mano si un miembro del comité o un lector pregunta cómo se compara Honduras a nivel regional — vale la pena tenerlo presente, no vale la pena forzarlo.

Paso 10 — Visualiza en Looker Studio

CONCEPTO(S) DE LA CERTIFICACIÓN: Meta de gobernanza: hacer los datos accesibles y utilizables · flujo de trabajo del analista: reportar

■ DÓNDE EJECUTARLO: No es la consola de Google Cloud — es un sitio aparte: lookerstudio.google.com. Inicia sesión con la misma cuenta de Google, haz clic en "En blanco" / "Blank Report", y cuando te pida una fuente de datos, elige el conector "BigQuery", selecciona tu proyecto (`world-bank-wdi`) y el dataset `wdi_curated`.

- Un gráfico de línea del desempleo por país a través del tiempo (del 9a) — la línea de Honduras debería resaltar visualmente frente a sus pares regionales.
- Un gráfico de dispersión de crecimiento del PIB vs. desempleo (del 9b), un punto por país-año — la forma clásica de la ley de Okun, o su ausencia, es la historia aquí.
- Un control de filtro simple por región y rango de años, para que el dashboard se sienta como una herramienta y no como un solo gráfico fijo.

Paso 11 — Dónde los conceptos de streaming honestamente no aplican, y por qué decirlo es la decisión correcta

> **CONCEPTO(S) DE LA CERTIFICACIÓN: Arquitectura de streaming vs. batch (Kafka/Avro/NiFi) — criterio, no aplicación forzada**

WDI se actualiza anualmente, no de forma continua — aquí no hay un flujo de eventos en tiempo real genuino, y forzar un componente de Kafka/Avro/NiFi en este proyecto sería artificial en vez de útil. El equivalente honesto es una **consulta programada (scheduled query)** en BigQuery, que vuelva a ejecutar el pivoteo del Paso 5 de forma periódica (por ejemplo, anualmente, siguiendo la propia cadencia de actualización de la fuente) para que la capa curada se refresque sin intervención manual. Reconocer cuándo un concepto no encaja con la carga de trabajo y explicar por qué, en vez de agregarlo a la fuerza solo para marcar una casilla, es en sí mismo una señal de entender el material de la certificación en vez de solo recitarlo — vale la pena decirlo explícitamente en tu README.

> **■ DÓNDE EJECUTARLO: Para programar la consulta: en BigQuery Studio, después de ejecutar la consulta del Paso 5 al menos una vez, haz clic en el botón “Programar” / “Schedule” que aparece junto al botón “Ejecutar” — no en la Terminal.**

Paso 12 — Empaquétalo, con el mapa de conceptos como parte del entregable

> **CONCEPTO(S) DE LA CERTIFICACIÓN: Todo lo anterior, hecho explícito para alguien que no lo construyó contigo**

Estructura el README con una sección literalmente titulada **"Conceptos de la certificación demostrados"**, listando cada concepto de esta guía junto con la línea de SQL o la decisión de diseño donde aparece. Esto logra dos cosas a la vez: te obliga a volver a articular cada concepto en tus propias palabras una vez más (la mejor forma de comprobar si realmente se te quedó), y le da a cualquiera que revise tu portafolio — incluido un reclutador — un mapa inmediato y explícito de tu profundidad, en vez de dejar que lo infiera solo a partir del SQL.

Entre este proyecto y Olist, habrás ejercitado deliberadamente: normalización y las principales técnicas de desnormalización (JOINs en Olist, pivoteo aquí), esquemas en estrella, anidamiento con STRUCT, los cuatro componentes de la gobernanza de datos, el catalogado de datos y los glosarios de negocio, el lado batch de la distinción streaming-vs-batch (junto con una explicación razonada de por qué el lado streaming no aplica), y el flujo de trabajo completo del analista desde el descubrimiento hasta el reporte. Eso no es un repaso superficial de la certificación — es el contenido de la certificación sosteniendo dos piezas de trabajo reales y explicables.